

# PCS3616 - Laboratório 2 - Introdução ao UNIX 2

## Ferramentas básicas

### Programação com vim, gcc, gdb e make

#### Introdução

Nessa aula, você vai aprender para que servem e como usar algumas ferramentas que irá encontrar em qualquer projeto de software de porte razoável. Quanto mais complexo o projeto (em termos de quantidade de código e de componentes, número de pessoas envolvidas, dependências de bibliotecas externas, etc), mais essas ferramentas se tornam importantes para auxiliá-lo a se manter produtivo e colocar o computador para trabalhar a seu favor.

O conjunto das ferramentas usadas em um projeto de software é normalmente conhecido como [toolchain](#). Dependendo da complexidade do projeto, a sua *toolchain* irá conter um número maior ou menor de ferramentas, e isso vale para o desenvolvimento de qualquer sistema e em qualquer linguagem de programação. Para deixar a discussão mais concreta, vamos falar sobre desenvolvimento em C, que é uma das linguagens mais usadas quando se trata de software básico.

Para escrever e executar um programa em C, o mínimo que você precisa é de:

- Um **editor de texto**, para escrever o código-fonte do programa;
- Um **compilador**, para converter o código-fonte em um arquivo executável escrito em linguagem de máquina (código binário). O executável resultante do processo de compilação será interpretado e executado pelo sistema operacional e pelo hardware.

A princípio, é só isso! Com essas duas ferramentas, você já pode escrever qualquer programa imaginável e executá-lo, mas existem muitas outras ferramentas que vão tornar a sua vida muito mais fácil se o seu programa for minimamente complexo.

Por exemplo, você roda o programa e descobre que ele não está se comportando *exatamente* como esperado... Às vezes ele produz o resultado certo, às vezes não. Relendo o código, você não encontra nada de errado. Como descobrir o que está acontecendo? Agora é um bom momento para introduzir mais uma ferramenta:

- Um **debugger**, que permite que você execute o seu programa passo-a-passo, inspecionando como o estado do programa vai sendo alterado durante a execução—por exemplo, mudanças nos valores de variáveis. Com um debugger, você pode acompanhar a execução do programa desde o início ou interromper a execução quando ele chegar em uma determinada linha de código.

Uma outra etapa do processo de desenvolvimento é que comumente automatizada é a etapa de *build*. Por exemplo, digamos que toda vez que você faz alguma alteração no software, precisa realizar os seguintes passos:

- Recompilar o projeto (para projetos muito grandes e dependendo da capacidade do seu computador, a compilação de todos os arquivos pode demorar de minutos a algumas horas);
- Executar testes automatizados com o executável—por exemplo, para garantir que a correção de um bug não introduziu novos bugs em outros componentes;
- Mover o executável para o diretório onde o seu sistema operacional espera encontrar executáveis (que normalmente é qualquer diretório no seu \$PATH).

Os passos acima podem ser automatizados de diversas formas. Uma delas é escrever um *shell script*, simplesmente. A outra, muito comum, é usar uma **ferramenta de build**, que permite que você declare receitas para obter determinados artefatos a partir de outros—por exemplo, como obter um arquivo executável a partir dos arquivos-fonte do seu projeto.

Para cada uma das ferramentas citadas acima, existem diversas opções de programas, acessíveis, inclusive, pela linha de comando. A tabela a seguir lista alguns exemplos.

Ferramenta	Programas
Editor de texto	nano, vi/vim, emacs, gedit
Compilador	gcc, clang, icc, javac (Java)
Debugger	gdb, lldb
Ferramenta de build	make, rake (Ruby), ant (Java)

Note que o compilador e o debugger são ferramentas que dependem da linguagem de programação usada para desenvolvimento, enquanto o editor de texto e a ferramenta de build normalmente são independentes de uma linguagem.

No restante do tutorial, vamos falar sobre um programa para cada ferramenta: **vim**, **gcc**, **gdb** e **make**.

## Editor de texto: vim

O vim é um editor de texto usado diretamente pela linha de comando (apesar de também poder ser usado com uma interface gráfica). Para editar um arquivo de texto com o vim, basta digitar:

```
vim <caminho_para_o_arquivo>
```

Por exemplo:

```
vim ~/.bashrc
```

O vim funciona de uma maneira um pouco diferente da que você provavelmente está acostumado. Ele possui dois modos de operação distintos: modo de comando (*command mode*) e modo de edição (*insert mode*).

O modo de comando, que é o modo em que o vim se encontra quando é iniciado, permite que você navegue pelo texto e faça alterações no arquivo usando... *wait for it...* comandos.

Por exemplo, se você abrir um arquivo no vim, levar o cursor até uma determinada letra e apertar a tecla x, o caractere em que o cursor está posicionado será excluído, ao invés da letra "x" ser adicionada ao texto. Ou seja: **no modo de comando, as teclas do seu teclado servem para executar comandos, ao invés de inserir caracteres no texto.**

O modo em que você usa o teclado para realmente digitar caracteres é o modo de edição. Para entrar no modo de edição, o comando é a tecla i ou a tecla insert. Se você estiver no modo de edição, o texto -- INSERT -- será mostrado no canto inferior esquerdo da tela.

Sobre o modo de edição não há muito o que falar porque, neste modo, o vim se comporta como qualquer editor comum.

Sobre o modo de comando, o que você precisa saber são os comandos. Vamos mostrar alguns aqui, mas existem muitos outros. A tabela abaixo lista alguns dos mais comuns:

Comando	Descrição
:q	Sai do editor ( <i>quit</i> )
:w	Salva o arquivo ( <i>write</i> )
:wq	Salva o arquivo e sai ( <i>write and quit</i> )
:q!	Sai do editor (descartando alterações não salvas)
i	Entra no modo de edição ( <i>insert mode</i> )
Esc	Entra no modo de comando ( <i>command mode</i> )
j, k, l, h	Move o cursor para baixo, cima, direita e esquerda, respectivamente
gg	Move o cursor para o início do arquivo

Shift + g	Move o cursor para o final do arquivo
\$	Move o cursor para o final da linha
0	Move o cursor para o início da linha
:N	Move o cursor para a linha N
dd	Apaga a linha atual

## Compilador: gcc

O gcc é um compilador: um programa que permite converter um ou mais arquivos-fonte escritos em C em um arquivo executável. Na verdade, falando mais rigorosamente, o gcc é um *compiler driver*, pois ele executa outros passos além da compilação, mas não vamos entrar nesses detalhes ainda.

O tópico de compilação de um programa (independente das linguagens de entrada e de saída) é uma das áreas mais complexas e interessantes da Computação. Um dos motivos para a complexidade é que existem muitas decisões que precisam ser tomadas ao longo do processo de compilação.

Por exemplo: qual a plataforma em que o programa será executado? Muitas vezes, você compila um programa em um computador, mas irá executá-lo em outro. Você gostaria de otimizar o código gerado? Se sim, gostaria de otimizar de acordo com qual parâmetro de desempenho: tamanho do executável, uso de memória (*memory footprint*), tempo de execução, ...? Onde o compilador deve procurar para encontrar bibliotecas externas que serão usadas pelo seu programa?

Dependendo da sua necessidade, o uso do gcc pode ficar bastante complexo. No entanto, para casos de uso simples, a linha de comando é igualmente simples:

```
gcc -o <arquivo_de_saida> <arquivo_de_entrada>
```

Por exemplo:

```
gcc -o foo foo.c
```

Depois de executar esse comando, se não houver nenhum erro, você poderá executar o programa pelo terminal:

```
./foo
```

**Exercício 1.1:** Utilize o template abaixo para criar o arquivo `fatorial.c`. Usando o vim, edite o arquivo de tal forma que o programa funcione corretamente (veja os comentários no código). Em seguida, compile e execute o programa usando o gcc.

### Template:

```
#include <stdio.h>

int fatorial(int n);

/**
 * Ponto de entrada do programa (entry point).
 */
int main(int argc, char** argv) {
    int n;
    scanf("%d", &n);

    printf("%d\n", fatorial(n));

    return 0;
}

/**
 * Calcula o fatorial do número recebido e retorna o resultado.
 */
int fatorial(int n) {
    // Por enquanto, essa função não faz nada de muito útil... Ela apenas
    // retorna o número recebido.
    // Altere esta implementação para retornar o resultado correto.
    return n;
}
```

### Exemplo de execução:

```
$ ./fatorial
4
24
```

**Entrega:** o arquivo fatorial.c

**Atenção:** o algoritmo será corrigido automaticamente. Para que ele possa funcionar corretamente, em todo o corpo do código, receba apenas um único número de entrada, o valor a ser calculado seu fatorial, e imprima uma única saída, o fatorial correspondente. Caso o código apresente falha de execução ou não passe em todos os testes de avaliação, você poderá editá-lo e submetê-lo novamente.

## Debugger: gdb

O gdb é um **debugger**: um programa que permite acompanhar a execução de um programa e também interferir nela. O gdb funciona com muitas linguagens, mas as mais comuns são C e C++.

O uso do gdb será demonstrado a partir do exemplo abaixo, que mostra como descobrir a causa de um erro de *segmentation fault* em um programa. Esse exemplo é uma tradução/adaptação do original disponível [aqui](#).

### Usando o gdb para resolver um problema de *segfault*

Neste exemplo, você irá aprender a usar o gdb para descobrir por que o programa abaixo, quando executado, causa um erro de *segmentation fault*.

O programa deveria ler uma linha de texto do usuário e imprimi-la. No entanto, veremos que, do jeito como está, o resultado não é exatamente esse...

#### Versão inicial (com bug) do programa:

```
#include <stdio.h>
#include <stdlib.h>

int main(int argc, char **argv)
{
    printf("Digite um texto qualquer e pressione Enter ao final:\n");

    char *buf;
    buf = malloc(1<<31);
    fgets(buf, 1024, stdin);

    printf("Texto digitado foi:\n");
    printf("%s\n", buf);

    return 1;
}
```

Crie um arquivo chamado segfault-example.c, com o conteúdo acima. Compile o arquivo usando o gcc e o execute, para verificarmos se realmente existe um problema:

```
gcc -o segfault-example segfault-example.c
./segfault-example
```

Você deve ter observado que, realmente, o programa termina com erro antes de imprimir a linha digitada pelo usuário. Vamos usar o gdb, então, para descobrir o motivo.

O primeiro passo é recompilar o arquivo usando a flag -g, que faz com que o gcc compile o programa de uma forma ligeiramente diferente, incluindo símbolos que serão usados pelo gdb.

```
gcc -g -o segfault-example segfault-example.c
```

Agora, execute o programa novamente, dessa vez pelo gdb:

```
$ gdb segfault-example
[várias linhas na saída, omitidas]
Reading symbols from segfault-example...done.
(gdb)
```

Nesse ponto, o gdb está pronto e aguardando instruções. Para começar, vamos simplesmente executar o programa usando o comando run e ver o que acontece:

```
(gdb) run
Starting program:
/home/deborasetton/Documents/Mestrado/Monitoria/PCS3616-Systems-Programming/aula2/segfault-example
Digite um texto qualquer e pressione Enter ao final:
QUALQUER COISA AQUI

Program received signal SIGSEGV, Segmentation fault.
__GI__IO_getline_info (fp=fp@entry=0x7ffff7dd3980 <_IO_2_1_stdin_>,
buf=buf@entry=0x0, n=1022, delim=delim@entry=10,
extract_delim=extract_delim@entry=1, eof=eof@entry=0x0) at iogetline.c:86
86      iogetline.c: No such file or directory.
(gdb)
```

O gdb executa o programa até onde consegue e para novamente, informando que recebeu o sinal SIGSEGV do sistema operacional. Isso significa que o programa tentou acessar uma região de memória inválida.

Vamos usar o comando backtrace para descobrir onde exatamente o programa travou:

```
(gdb) backtrace
#0  __GI__IO_getline_info (fp=fp@entry=0x7ffff7dd3980 <_IO_2_1_stdin_>,
buf=buf@entry=0x0, n=1022, delim=delim@entry=10,
extract_delim=extract_delim@entry=1, eof=eof@entry=0x0) at iogetline.c:86
#1  0x00007ffff7a7f188 in __GI__IO_getline (fp=fp@entry=0x7ffff7dd3980
<_IO_2_1_stdin_>, buf=buf@entry=0x0, n=<optimized out>,
delim=delim@entry=10, extract_delim=extract_delim@entry=1) at
iogetline.c:38
#2  0x00007ffff7a7dfc4 in _IO_fgets (buf=0x0, n=<optimized out>,
```

```
fp=0x7ffff7dd3980 <_IO_2_1_stdin_>) at iofgets.c:56
#3 0x000000000400647 in main (argc=1, argv=0x7fffffd5c8) at
segfault-example.c:10
(gdb)
```

Repare que a saída do comando faz referência a alguns arquivos que o programa usa, mas que não fomos nós que escrevemos, como iogetline.c e iofgets.c.

Como estamos interessados no nosso próprio código, vamos usar o comando frame para ir até o frame **3**, que é o frame que fala sobre o nosso arquivo, segfault-example.c:

```
(gdb) frame 3
#3 0x000000000400647 in main (argc=1, argv=0x7fffffd5c8) at
segfault-example.c:10
10      fgets(buf, 1024, stdin);
(gdb)
```

Ok, então o programa travou na chamada à função fgets. De maneira geral, sempre podemos assumir que funções da biblioteca padrão, como esta, estão funcionando -- se este não for o caso, o problema é muito maior.

Portanto, o problema deve estar em um dos 3 argumentos que passamos para a função. Talvez você não saiba, mas stdin é uma variável global que é criada pela biblioteca stdio, então este argumento podemos assumir que está ok. Resta o argumento buf.

Vamos usar o comando print para inspecionar o valor desta variável:

```
(gdb) print buf
$1 = 0x0
(gdb)
```

O valor da variável é 0x0, que é o ponteiro nulo. Isso não é o que queremos -- buf deveria apontar para uma área de memória que foi alocada na chamada ao malloc (veja o código).

Portanto, vamos ter que descobrir o que aconteceu aqui. Mas antes, podemos encerrar a instância atual do programa (que já nos deu informações suficientes e não tem mais o que executar) usando o comando kill:

```
(gdb) kill
Kill the program being debugged? (y or n) y
(gdb)
```

Após este comando, estamos novamente no início do gdb. Desta vez, vamos colocar um breakpoint na linha do código que chama o malloc:



```
(gdb) break segfault-example.c:9
Breakpoint 1 at 0x40062f: file segfault-example.c, line 9.
(gdb)
```

Agora, vamos rodar o programa novamente:

```
(gdb) run
Starting program:
/home/deborasetton/Documents/Mestrado/Monitoria/PCS3616-Systems-Programmi
ng/aula2/segfault-example
Digite um texto qualquer e pressione Enter ao final:

Breakpoint 1, main (argc=1, argv=0x7fffffff5c8) at segfault-example.c:9
9      buf = malloc(1<<31);
(gdb)
```

Primeiro, vamos ver qual é o valor de buf antes da chamada ao malloc, usando o comando print. Uma vez que essa variável ainda não foi inicializada, esperamos que o valor seja inválido, e realmente é:

```
(gdb) print buf
$1 = 0x0
(gdb)
```

Agora, vamos usar o comando next para executar apenas esta linha de código e parar novamente, para podermos ver o que aconteceu com a variável:

```
(gdb) next
10      fgets(buf, 1024, stdin);
(gdb) print buf
$2 = 0x0
(gdb)
```

Após a chamada, verificamos que buf continua inválido, apontando para NULL. Por quê? Se você consultar a documentação do malloc, descobrirá que essa função retorna NULL quando não consegue alocar a quantidade de memória solicitada. Portanto, a chamada ao malloc feita pelo nosso programa deve ter falhado. Vamos olhar essa chamada novamente:

```
buf = malloc(1<<31);
```

Bom... O valor da expressão `1 << 31` (o inteiro 1 deslocado 31 bits à esquerda) é 429497295 ou 4GB. Poucos sistemas operacionais alocariam esta quantidade de memória para um único programa, a não ser com configurações especiais, então é claro que o malloc

falhou. Além disso, nós só estamos lendo 1024 bytes com o `fgets`, então para que alocar tanta memória?

Mude o valor `1<<31` no código-fonte para 1024, compile e execute o programa novamente:

```
$ gcc -o segfault-example segfault-example.c
$ ./segfault-example
Digite um texto qualquer e pressione Enter ao final:
QUALQUER COISA AQUI
Texto digitado foi:
QUALQUER COISA AQUI
```

Problema resolvido! \o/

E agora você sabe como depurar segfaults usando o `gdb`, o que é extremamente útil. Finalmente, este exemplo também ilustra um outro ponto muito importante: **sempre verifique o valor retornado pelo `malloc`**!

## Debugger: make

A última ferramenta de que vamos falar aqui é o `make`, que permite a automatização de muitas operações, e é comumente utilizado para gerenciar o processo de build de um software.

O `make` é basicamente uma ferramenta que executa comandos do shell condicionalmente (normalmente, dependendo do estado de um ou mais arquivos). Um caso de uso muito comum para o `make` é o seguinte: imagine um software composto por centenas de arquivos em C. Compilar todos esses arquivos e construir os executáveis necessários leva, digamos, 40 minutos. Você estava corrigindo um bug no sistema e, para corrigir o bug, precisou alterar apenas 3 arquivos do projeto; por volta de 10 linhas foram modificadas ao todo.

Agora, você precisa obter novos executáveis, compilados a partir do código modificado. Não é possível recompilar apenas os 3 arquivos que foram alterados, porque existem outros arquivos que dependem destes 3, então eles precisarão ser recompilados também. E, então, os arquivos que dependem *desses outros* também precisarão ser recompilados... O que você acha de montar essa lista de quais arquivos precisarão ser recompilados manualmente, olhando arquivo por arquivo? Ou será que é melhor compilar tudo do zero e esperar os 40 minutos de uma vez?

Nenhuma dessas opções é ideal, mas a boa notícia é que o `make` ajuda a resolver exatamente esse tipo de problema: se você disser quais arquivos dependem de quais (e dessa vez é suficiente informar apenas o primeiro nível de dependência), o `make` utiliza a data de modificação dos arquivos para descobrir se um determinado executável precisa ser recompilado ou não, com base na data de modificação de suas dependências.

O arquivo que informa o make sobre as dependências de cada arquivo, contém instruções sobre como (re-)construir executáveis, executar testes, etc em um projeto é o Makefile.

## Makefile

Um Makefile é um arquivo que contém **regras** (*rules*). Cada regra define como construir um ou mais **targets** a partir de dois itens: uma lista de dependências (*prerequisites*, que pode ser vazia) e uma **receita** (*recipe*), que são apenas comandos que serão executados em um shell.

A sintaxe básica de uma regra de um Makefile é:

```
# Sintaxe de uma regra.
# Linhas que começam com '#', como estas, são comentários.

targets : prerequisites
    recipe_line_1
    recipe_line_2
    ...
    recipe_line_n
```

Uma observação importante é que todas as linhas de uma receita devem começar com o caractere Tab (\t). Por isso, atenção para usar Tabs e não espaços. O seu editor de texto pode ser configurado (se já não estiver) para mostrar espaços em branco no texto, distinguindo tabs de espaços.

## Exemplo de Makefile

Saindo um pouco do contexto de programação, o arquivo abaixo é um Makefile que define como construir um arquivo groceries.txt a partir de outros dois arquivos, fruits.txt e vegetables.txt. Quem nunca quis controlar a lista do supermercado usando Makefiles, certo?!

```
SHELL=/bin/bash

# Este Makefile contém 4 regras, descritas abaixo.

# Esta primeira regra contém apenas um target: o arquivo groceries.txt.
# Para que o make consiga construir o arquivo, outros dois arquivos estão
# listados como dependências: um com a lista de frutas e outro com a
# lista de legumes.
# Se as dependências forem satisfeitas, o make executa as linhas de
# receita, que apenas imprime o conteúdo dos dois arquivos em um arquivo
# final, acrescentando linhas de cabeçalho.
# Importante: cada linha é executada em uma nova instância nova de um
```

```

# shell (o que significa, por exemplo, que variáveis definidas em uma
# linha não estarão disponíveis nas linhas seguintes).
#
-----
groceries.txt : fruits.txt vegetables.txt
    echo -e "Fruits:\n" > groceries.txt
    cat fruits.txt >> groceries.txt
    echo -e "\nVegetables:\n" >> groceries.txt
    cat vegetables.txt >> groceries.txt

# Esta regra contém dois targets. Nenhum deles tem dependências, e a
# receita apenas imprime uma mensagem dizendo para o usuário criar o
# arquivo correspondente.
#
-----
fruits.txt vegetables.txt:
    echo "Please create the file $@"

# Esta é uma regra auxiliar. O target `clean` não é um arquivo que será
# criado; a regra é basicamente um atalho para executar uma linha de
# comando. Nesse caso, a receita apaga o arquivo groceries.txt.
#
-----
clean:
    rm -f groceries.txt

# Esta é uma outra regra auxiliar, que imprime o conteúdo do arquivo de
# saída (o que significa que faz sentido listá-lo como dependência).
#
-----
print : groceries.txt
    cat groceries.txt

```

## Como usar o make na linha de comando

O uso básico do make é:

```
make <target>
```

Com este comando, o make irá procurar um Makefile (que é apenas um arquivo com este nome) no mesmo diretório em que o comando foi executado (a opção -f pode ser usada caso o Makefile esteja em outro diretório).

Em seguida, irá analisar o Makefile para encontrar uma regra que ensine como construir o *target* passado como parâmetro. Se o *target* tiver dependências pendentes, elas serão construídas primeiro, e assim por diante.

Por exemplo, para construir o arquivo groceries.txt usando o Makefile acima:

```
make groceries.txt
```

**Exercício 1.2:** criar um Makefile (usando o vim) com o conteúdo do exemplo acima. Em seguida, criar um shell script chamado makefile-test.sh que chama, um por um, todos os targets possíveis desse Makefile (dica: são 5).

**Entrega:** Um zip (makefile-test.zip) contendo o shell script ( makefile-test.sh )

**Exercício 1.3:** criar um Makefile (usando o vim) para o programa do fatorial. O Makefile deve definir as seguintes regras:

1. Compilar o arquivo fatorial.c (com o método main() ) usando o gcc. O nome do target (e do executável produzido) deve ser fatorial.
2. Executar o arquivo fatorial, caso ele exista. Esta regra não deve compilar o arquivo, apenas chamar o executável. Nome do target: run.
3. Executar o arquivo no gdb. Na receita, você deve compilar o arquivo com a flag necessária para usar o gdb e, em seguida, chamar o executável. Nome do target: run\_gdb.
4. Remover o executável. Nome do target: clean.

**Entrega:** Um arquivo zip com nome lab2-atv3-XXXXXX.zip e com os seguintes arquivos:

```
lab2-atv3-XXXXXX.zip/  
├── fatorial.c  
└── Makefile
```

## Expressões regulares

### Introdução

O conceito de **expressão regular** é um dos conceitos teóricos mais importantes de Computação, e também é muito usado na prática, em diversos tipos de atividades, como:

- Encontrar um arquivo no seu computador cujo texto contenha um determinado padrão. Por exemplo, encontrar todos os arquivos em um determinado diretório que contenham um número de CPF ou CNPJ.
- Verificar informações fornecidas por usuários que devem obedecer a formatos específicos, como números de telefone, endereços de email, CPF, RG, CEP, etc;
- Verificar se um determinado trecho de código é sintaticamente correto, isso é, se obedece à sintaxe da linguagem de programação em que foi escrito;

- Efetuar substituições de texto em um ou mais arquivos, caso o conteúdo obedeça um determinado padrão. Por exemplo substituir todas as ocorrências de "pcs", "psi" e "pea" em um conjunto de arquivos por "PCS", "PSI" e "PEA", respectivamente;
- Extrair informações em páginas da Web. Por exemplo, capturar os preços de produtos em uma página de busca do Buscapé.

O termo "expressão regular" também é conhecido por **regex** ou **regexp** (contração do termo em Inglês, *regular expression*).

Você pode pensar em uma expressão regular como um "padrão" ou uma "forma" que é usada para generalizar e descrever um conjunto de *strings* (sequências de caracteres) sem precisar listar cada string individualmente.

Por exemplo, digamos que você queira encontrar todos os números de CPF em um texto. Como o número de strings que representam CPFs é muito grande para listar um por um, você pode usar uma expressão regular que se "encaixe" em qualquer número de CPF, como este:

<NUM><NUM><NUM><PONTO><NUM><NUM><NUM><PONTO><NUM><NUM><NUM><TRAÇO><NUM><NUM>

Onde: - <NUM> é qualquer dígito entre 0 e 9; - <PONTO> é o caractere de um ponto (.); - <TRAÇO> é o caractere de hífen (-);

Qualquer CPF válido e pontuado obedecerá ao padrão definido acima.

Outro exemplo: um padrão para encontrar números de telefone, sem considerar o DDD. Telefones móveis têm 9 dígitos, enquanto telefones fixos têm 8. Um possível padrão seria:

<NUM\_OPCIONAL><NUMx4>-<NUMx4>

Onde: - <NUM\_OPCIONAL> é qualquer dígito ou a string vazia; - <NUMx4> é uma sequência de 4 dígitos quaisquer; - O traço (-) representa ele mesmo.

## Sintaxe

Como você pode ver, não basta conseguir definir o seu termo de busca como um padrão. Precisamos definir uma sintaxe (um formato) para esses padrões. Vamos usar <TRAÇO> ou - para definir um hífen? Vamos usar <NUM> várias vezes ou poderemos escrever coisas como <NUMx10> quando quisermos especificar sequências do mesmo tipo de caractere?

Quase todas as linguagens e ferramentas que suportam o uso de expressões regulares utilizam a mesma sintaxe e, para poder usar expressões regulares no seu dia-a-dia, você também precisa conhecê-la.

A tabela abaixo é uma referência resumida dessa sintaxe (veja outras referências, mais completas, na seção [Recursos Adicionais](#)).

## Referência

	Significado	Exemplo	Strings válidas	Strings inválidas
caractere comum	Qualquer caractere que não seja especial corresponde a ele mesmo. Os caracteres especiais são: {}[]()^\$. *+?\ e -, quando aparece dentro de colchetes ([]).	frio	<ul style="list-style-type: none"> <li>frio</li> <li>Hoje está frio. (a regex pode aparecer em qualquer posição da string que está sob análise)</li> <li>Você prefere frio ou calor?</li> </ul>	<ul style="list-style-type: none"> <li>Frio (regexes são, por padrão, <i>case-sensitive</i>)</li> <li>fr-io</li> </ul>
.	Corresponde a qualquer caractere, com exceção do \n	m.r	<ul style="list-style-type: none"> <li>mar</li> <li>amor</li> <li>Que horas vamos comer?</li> </ul>	<ul style="list-style-type: none"> <li>semear</li> </ul>
?	O caractere ou grupo precedente é opcional (i.e., pode estar presente ou ausente).	carro?	<ul style="list-style-type: none"> <li>carro</li> <li>carr</li> <li>carros</li> <li>carroça</li> </ul>	
*	Especifica que o caractere ou grupo que precede o '*' deve aparecer 0 ou mais vezes.	ba*	<ul style="list-style-type: none"> <li>b</li> <li>ba</li> <li>baa</li> <li>baaaaaaaaaaaa</li> <li>aaa</li> </ul>	<ul style="list-style-type: none"> <li>a</li> </ul>
+	Especifica que o caractere ou grupo que precede o '+' deve aparecer 1 ou mais vezes.	ba+	<ul style="list-style-type: none"> <li>ba</li> <li>baa</li> <li>baaaaaaaaaaaa</li> <li>aaa</li> </ul>	<ul style="list-style-type: none"> <li>b</li> <li>a</li> </ul>

{n}	Especifica que o caractere ou grupo que precedente deve aparecer exatamente `n` vezes.	ba{3}	<ul style="list-style-type: none"> <li>• baaa</li> </ul>	<ul style="list-style-type: none"> <li>• b</li> <li>• ba</li> <li>• baaaa</li> </ul>
	Especifica conjunção (`OR`).	ba(nana rraca)	<ul style="list-style-type: none"> <li>• banana</li> <li>• barraca</li> </ul>	<ul style="list-style-type: none"> <li>• ba</li> </ul>
[abc123]	Colchetes são usados para definir opções. Um grupo entre colchetes corresponde a qualquer um (e apenas um) dos caracteres especificados entre os colchetes.	[2345]	<ul style="list-style-type: none"> <li>• 2 itens</li> <li>• 3 itens</li> </ul>	<ul style="list-style-type: none"> <li>• 24 itens</li> </ul>
\d	Corresponde a qualquer dígito. Equivalente a `[0-9]`.	\d	<ul style="list-style-type: none"> <li>• 0 itens</li> <li>• 9 itens</li> </ul>	<ul style="list-style-type: none"> <li>• 0 itens</li> <li>• 9 itens</li> </ul>
\s	Corresponde a espaços em branco (` `, `t`, `n`).	a\s	<ul style="list-style-type: none"> <li>• a b</li> </ul>	<ul style="list-style-type: none"> <li>• ab</li> </ul>
^	Corresponde ao início da string, ou início de uma linha, caso o texto tenha múltiplas linhas.	^v	<ul style="list-style-type: none"> <li>• você tem quantos anos?</li> </ul>	<ul style="list-style-type: none"> <li>• quantos anos você tem?</li> </ul>
\$	Corresponde ao final da string, ou final de uma linha, caso o texto tenha múltiplas linhas.	!\$	<ul style="list-style-type: none"> <li>• Olá!</li> <li>• Tudo bem?!</li> </ul>	<ul style="list-style-type: none"> <li>• Olá.</li> </ul>



( )	Parênteses são usados tanto para agrupamento quanto para captura.	ba(na){2}	<ul style="list-style-type: none"> <li>• banana</li> <li>• bananada</li> <li>• Doce de banana é bom.</li> </ul>	<ul style="list-style-type: none"> <li>• abanar</li> <li>• cabana</li> </ul>
-----	---	-----------	---	--

Observação: para escrever uma expressão regular que reconheça caracteres que normalmente teriam um significado especial (e.g., ., ?, (, ), \$), basta escapar estes caracteres com uma barra invertida, \. Por exemplo: a expressão que horas são\? reconheceria a string "Pode me dizer que horas são?", porque o ponto de interrogação está devidamente escapado.

## Uso prático de expressões regulares

Muitas linguagens de programação e ferramentas possuem suporte à interpretação de expressões regulares. A maioria das linguagens de programação populares possui mecanismos nativos para a manipulação e uso de expressões regulares. Além disso, muitas ferramentas de linha de comando, como find, grep, sed e awk são comumente usadas com regexes.

O conceito de expressão regular é muito poderoso e é uma ferramenta essencial para resolver diversos problemas práticos. Por outro lado, para alguns problemas, a expressão regular correta pode ser bastante complexa e, sem a devida documentação, impossível de ser compreendida mais tarde—veja [este exemplo](#) da expressão regular oficial para reconhecer endereços de email em diversas linguagens.

Para encerrar, uma citação de [Jamie Zawinski](#), co-fundador do Netscape e do Mozilla:

Some people, when confronted with a problem, think "I know, I'll use regular expressions." Now they have two problems.

## Exercícios

Escreva expressões regulares para reconhecer os padrões descritos abaixo. Leia o enunciado até o final antes de começar.

Número do exercício	Descrição	Exemplos válidos	Exemplos inválidos
2.1	Um número USP (7 ou 8 dígitos), sem traços, pontos ou qualquer sinal de pontuação entre os dígitos.	<ul style="list-style-type: none"> <li>• 7581993</li> <li>• Meu número USP é: 10336827.</li> </ul>	<ul style="list-style-type: none"> <li>• 7581-993</li> </ul>

2.2	Número de telefone (fixo ou celular), com DDD entre parênteses, código do país precedido por "+" e espaços. Sem traços.	<ul style="list-style-type: none"> <li>+55 (11) 999994321</li> <li>+55 (51) 36975544</li> </ul>	<ul style="list-style-type: none"> <li>55 (11) 99999</li> <li>+55 (11) 9-9999-4321</li> </ul>
2.3	Linhas de um arquivo que começam com um número de até dois dígitos, seguido por parênteses e por uma frase qualquer. A linha deve terminar com um ponto de interrogação.	<ul style="list-style-type: none"> <li>1) Qual o seu nome?</li> <li>01) Qual o seu nome? E a sua idade?</li> </ul>	<ul style="list-style-type: none"> <li>01) Escreva o seu nome.</li> <li>(01) Escreva o seu nome.</li> </ul>
2.4	<p>Um nome próprio, com as seguintes restrições:</p> <ul style="list-style-type: none"> <li>No mínimo 2 nomes (nome e sobrenome) e no máximo 3.</li> <li>Todos os nomes devem começar com letra maiúscula (e este é o único lugar em que letras maiúsculas podem aparecer)</li> <li>O nome do meio, se presente, pode ser abreviado. A abreviação é a primeira letra do nome (maiúscula) seguida por um ponto</li> <li>Todos os nomes devem ter pelo menos 3 letras (a não ser que seja o nome do meio abreviado)</li> </ul>	<ul style="list-style-type: none"> <li>Alan Mathison Turing</li> <li>Ada Lovelace</li> <li>Richard M. Stallman</li> </ul>	<ul style="list-style-type: none"> <li>turing</li> <li>richie</li> <li>stallman</li> <li>LinuS</li> <li>Torvalds</li> <li>Edsger-Dijkstra</li> <li>Ed Dijkstra</li> </ul>

### Observações

- Nenhum destes exercícios tem uma resposta única. Dado um determinado padrão, é comum que existam várias expressões regulares que o reconheçam. Por exemplo, uma sequência de dois dígitos pode ser definida pelas expressões `\d\d`, `\d{2}`, `[0-9]{2}`, `[0123456789][0123456789]`, etc.

- Você pode usar o site [regex101](https://regex101.com) para testar e entender suas expressões regulares. Utilize os exemplos válidos e inválidos fornecidos no enunciado, e escreva a sua expressão lá, até ficar satisfeito com o resultado.

## Entrega

Entregar um arquivo zip com nome lab2-atv4-XXXXXX.zip contendo um único arquivo chamado regex.txt.

O arquivo deve conter uma linha para cada exercício da tabela acima, começando com o número do exercício, seguido de parênteses ()), 1 espaço e a expressão regular que você criou para resolver o problema.

Exemplo:

```
2.1) \b\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}\b
2.2) (19|20)\d\d
2.3) ^\s*#.*$
2.4) \*.*?\*/
```